



Giselli da Silva Mesquita | **RA:** 3025102489

Sara Nakagawa de Araujo | **RA:** 3024101436

Thiago Grecco Pacheco | **RA:** 3025201973.

Denis Cavalini dos Santos Junior | **RA:** 3023104223

Joyce Camelo de Souza | **RA:** 3023102570

Erick Adriano de Oliveira Silva | **RA:** 3025107900

Efraim Quintunda Fernandes | **A:** 323103429

Philipe Frazão Santos | **RA:** 423104636

Gabriell Silva França Lau | **RA:** 3025200966

Lucas Willian Oliveira da Silva | **RA:** 3023200898

PROJETO EM GESTÃO DE SISTEMAS COMPUTACIONAIS

LogiPrime

SÃO PAULO

2026

SUMÁRIO

1.INTRODUÇÃO.....	4
1.1.Contextualização.....	4
1.2.Problema.....	4
1.3.Objetivo Geral.....	4
1.4.Objetivos Específicos.....	4
2.SOBRE A EMPRESA.....	5
2.1.Nome da Empresa.....	5
2.2.Ramo de Atuação.....	5
2.3.Estrutura Operacional.....	5
3.DESENVOLVIMENTO DO PROJETO.....	6
4.GESTÃO DE PROJETOS.....	7
4.1.Termo de Abertura do Projeto (Project Charter).....	7,8,9
4.2.EAP - Estrutura Analítica do Projeto.....	9
4.3.Matriz RACI.....	10
4.4.Cronograma (Gantt).....	10,11
4.5.Gestão de Custos.....	11
4.6.Plano de Riscos.....	12
4.7.Plano de Comunicação.....	12
5.ANÁLISE DE DADOS.....	13
5.1.Base de Dados.....	13
5.2.Processo ETL (Extract, Transform, Load).....	13
5.3.KPIs Desenvolvidos.....	14
5.4.Visualização de Dados (DataViz).....	14
6.SEGURANÇA DA INFORMAÇÃO.....	15
6.1.Mapeamento de Ameaças.....	15
6.2.Adequação à LGPD (Lei Geral de Produção de Dados).....	15
6.3.Matriz GUT.....	15,16
6.4.Políticas de Autenticação.....	16
7.PESQUISA OPERACIONAL.....	17
7.1.Introdução à Pesquisa Operacional.....	17
7.2.Modelagem Matemática.....	17,18,19,20
7.3.Scripts Python.....	20,21,22,23
7.4.Análise de Cenários.....	23,24,25,26,27

8.RESULTADOS OBTIDOS.....	28,29,30
9.CONCLUSÃO.....	32,33

1. Introdução

1.1 Contextualização

O presente projeto está inserido no contexto da empresa LogiPrime, atuante no setor de logística e distribuição de produtos. A organização realiza operações de entrega que demandam planejamento eficiente, considerando fatores como localização dos clientes, prazos e utilização da frota.

Com o aumento da demanda e da complexidade das operações, torna-se necessário aprimorar os processos logísticos, especialmente no que se refere à definição de rotas de entrega.

1.2 Problema

O principal problema identificado na LogiPrime está relacionado à ineficiência no planejamento das rotas de entrega. A ausência de um sistema otimizado pode resultar em trajetos inadequados, aumento no tempo de entrega e elevação dos custos operacionais, evidenciando a necessidade de uma solução mais eficiente.

1.3 Objetivo Geral

Desenvolver e implementar um sistema inteligente de otimização de rotas para a empresa LogiPrime, com o objetivo de tornar o processo logístico mais eficiente e econômico.

1.4 Objetivos Específicos

- Análise dos dados históricos de entregas
- Identificação de padrões e gargalos logísticos
- Modelagem do problema
- Implementação de soluções tecnológicas
- Testes e validação da solução
- Avaliação dos resultados obtidos

2. Sobre a Empresa

2.1 Nome da Empresa

LogiPrime

2.2 Ramo de Atuação

A LogiPrime atua no segmento de logística e distribuição de produtos importados, realizando operações de transporte e entrega para diferentes regiões do estado de São Paulo. A empresa possui um centro de distribuição localizado na capital paulista, responsável pelo armazenamento, separação e expedição das mercadorias. Seu principal foco está na eficiência logística, buscando reduzir custos operacionais, otimizar rotas e garantir entregas rápidas e seguras aos clientes.

2.3 Estrutura Operacional

A estrutura operacional da LogiPrime é composta por uma frota fictícia de 25 caminhões destinados ao transporte e distribuição de produtos. A empresa realiza operações logísticas entre importantes cidades do estado de São Paulo, incluindo São Paulo, Santos, São José dos Campos, Campinas e Ribeirão Preto.

O fluxo operacional inicia-se no centro de distribuição localizado na capital paulista, onde os pedidos são organizados, separados e preparados para envio. A partir disso, as cargas são distribuídas entre os veículos disponíveis conforme a demanda de cada região.

3. Desenvolvimento do Projeto

INICIAÇÃO

Fase em que o projeto é definido, com identificação das necessidades da LogiPrime e das partes interessadas.

PLANEJAMENTO

Etapa responsável pela organização das atividades, definição do escopo, elaboração do cronograma e análise dos riscos.

ANÁLISE DE DADOS

Consiste na coleta e análise das informações logísticas, permitindo compreender o problema e identificar oportunidades de melhoria.

MODELAGEM

Refere-se à construção de uma representação lógica do problema, possibilitando o desenvolvimento de soluções mais eficientes.

DESENVOLVIMENTO

Fase em que a solução é implementada, incluindo o desenvolvimento do sistema.

TESTES

Etapa destinada à validação da solução, garantindo seu funcionamento adequado.

IMPLEMENTAÇÃO

Consiste na aplicação da solução no ambiente real e no treinamento dos usuários.

ENCERRAMENTO

Fase final, com avaliação dos resultados e documentação do projeto.

4. GESTÃO DE PROJETOS

Esta seção apresenta como o Projeto Integrador LogiPrime foi organizado, planejado e executado, abrangendo os principais instrumentos de gestão de projetos utilizados pela equipe de estudantes. As ferramentas adotadas seguem as boas práticas do gerenciamento de projetos delineadas pelo Guia PMBOK, garantindo organização, rastreabilidade, controle de prazos e alinhamento entre os membros da equipe multidisciplinar acadêmica.

4.1 Termo de Abertura do Projeto (Project Charter)

O Termo de Abertura do Projeto (TAP) consiste no documento formal que autoriza o início legal do projeto e concede ao gerente de projeto a autoridade necessária para aplicar os recursos (neste caso, o tempo e dedicação acadêmica da equipe) nas atividades planejadas. Ele registra de forma sintética os objetivos estratégicos, as justificativas, os escopos delimitados e as premissas fundamentais.

Objetivo do Projeto

Desenvolver e implementar um protótipo de sistema inteligente de otimização de rotas para o cenário simulado da empresa LogiPrime, com o objetivo de tornar o processo logístico significativamente mais eficiente e econômico. O projeto visa demonstrar a aplicação de modelos matemáticos e algoritmos de otimização desenvolvidos em ambiente acadêmico.

Stakeholders (Partes Interessadas)

No contexto deste projeto integrador universitário, os stakeholders compreendem:

- Corpo Docente / Banca Avaliadora: responsáveis por atuar como patrocinadores (sponsors) e aprovar os resultados e a viabilidade do projeto;
- Equipe de Alunos Desenvolvedores: encarregados do levantamento, codificação, testes e documentação da solução;
- LogiPrime (Empresa Fictícia/Estudo de Caso): representante do setor logístico que simula o usuário final e os requisitos do negócio.

Escopo do Projeto

O escopo abrange o desenvolvimento de uma solução de software acadêmica voltada à otimização das rotas de entrega, incluindo: análise de dados históricos (utilizando datasets públicos), modelagem matemática do problema de roteamento, scripts estruturados em linguagem Python, testes de bancada e apresentação dos resultados. Exclusões: não fazem parte do escopo aquisições de licenças de software pagas, contratação de infraestrutura empresarial ou implementação em um ambiente produtivo real físico.

Prazo

O projeto foi planejado para ser executado ao longo de um ciclo fechado de 9 semanas consecutivas, balizado pelo calendário acadêmico da instituição de ensino.

Restrições

As principais restrições identificadas que limitam a execução do projeto são:

- Limitações de prazo: o projeto possui data limite inegociável de entrega para avaliação;
- Restrição financeira (Custo Zero): não há orçamento real em dinheiro aprovado; toda a arquitetura tecnológica deve basear-se obrigatoriamente em ferramentas Open Source (código aberto), versões gratuitas para estudantes (Free Tier) e conjuntos de dados públicos;
- Limitações de hardware: o processamento dos algoritmos dependerá exclusivamente da capacidade computacional dos computadores pessoais (notebooks) dos membros da equipe.

Tabela 1 – Quadro Resumido do Termo de Abertura do Projeto (TAP)

CAMPO	DESCRIÇÃO
Nome do Projeto	LogiPrime – Otimização de Rotas Logísticas (Proj. Acadêmico)
Gerente do Projeto	Efraim Quintunda Fernandes
Data de Início	Março de 2026
Data de Término	Mai de 2026 (Semana 9)

Orçamento Financeiro	R\$ 0,00 (Uso exclusivo de tecnologias gratuitas e Open Source)
Objetivo Geral	Desenvolver protótipo de otimização de rotas via Python
Principais Stakeholders	Banca Avaliadora, Professores, Equipe de Alunos
Principais Restrições	Prazo letivo e obrigatoriedade de uso de ferramentas gratuitas

4.2 EAP – Estrutura Analítica do Projeto

A Estrutura Analítica do Projeto (EAP) consiste em uma ferramenta de decomposição hierárquica e sistemática orientada inteiramente às entregas. O projeto LogiPrime foi estruturado em oito fases lógicas e sequenciais para garantir que a equipe discente cumpra todas as sub entregas exigidas para a avaliação final.

Tabela 2 – Dicionário e Estrutura das Fases da EAP

FASE	NOME	DESCRIÇÃO
1	Iniciação	Definição do escopo acadêmico do projeto e necessidades do estudo de caso.
2	Planejamento	Elaboração do cronograma mestre e divisão de tarefas entre os alunos.
3	Análise de Dados	Coleta de dataset público de logística e análise exploratória de padrões.
4	Modelagem	Construção lógica e matemática do problema de roteamento.
5	Desenvolvimento	Escrita dos scripts em Python, usando bibliotecas Open Source e banco SQLite.
6	Testes	Validação computacional da solução nos computadores da equipe.
7	Implementação	Finalização do protótipo e geração dos indicadores (DataViz).
8	Encerramento	Elaboração da documentação técnica final e preparação da apresentação para a banca.

4.3 Matriz RACI

A matriz RACI é utilizada para definir os papéis e as responsabilidades de cada aluno membro da equipe em relação às entregas específicas do projeto (Responsável, Aprovador, Consultado, Informado). O líder Efraim Quintunda Fernandes atuou como Aprovado (A) na organização das entregas acadêmicas.

Tabela 3 – Matriz de Atribuição de Responsabilidades (RACI)

ENTREGA	R – Responsável	A – Aprovador	C – Consultado	I – Informado
TAP e Gestão	Efraim, Joyce	Efraim	Grupo	Todos
Cronograma e Riscos	Efraim, Joyce	Efraim	Grupo	Todos
Base de Dados/Dataset	Phillipe, Erick	Efraim	Grupo	Todos
Scripts Python (ETL)	Phillipe, Erick	Efraim	Grupo	Todos
KPIs e DataViz	Phillipe, Erick	Efraim	Grupo	Todos
Segurança e LGPD	Denis, Lucas	Efraim	Grupo	Todos
Modelagem e Algoritmos	Thiago, Sara	Efraim	Grupo	Todos
Documentação Final	Giselli, Gabriel	Efraim	Grupo	Todos

4.4 Cronograma (Gantt)

O cronograma define os marcos de início e término das tarefas letivas ao longo das 9 semanas do projeto. A metodologia visual adotada foi o Diagrama de Gantt.

Tabela 4 – Cronograma Geral de Atividades e Marcos de Conclusão

ATIVIDADE	RESPONSÁVEL	PERÍODO	TÉRMINO
Planejamento e Gestão	Efraim, Joyce	Semanas 1 a 3	Semana 3
Preparação da Base de Dados	Phillipe, Erick	Semanas 3 a 5	Semana 5
Desenvolvimento ETL	Phillipe, Erick	Semanas 3 a 5	Semana 5

Modelagem Matemática	Thiago, Sara	Semanas 4 a 6	Semana 6
Análise de Segurança / GUT	Denis, Lucas	Semanas 5 a 7	Semana 7
Geração de KPIs e Gráficos	Phillipe, Erick	Semanas 6 a 8	Semana 8
Documentação e Apresentação	Giselli, Gabriel	Semanas 7 a 9	Semana 9

4.5 Gestão de Custos

Como o LogiPrime é um projeto acadêmico de graduação, ele foi concebido com a premissa de Custo Financeiro Real igual a zero (R\$ 0,00). Toda a infraestrutura tecnológica utilizada baseia-se em recursos educacionais gratuitos e de código aberto. No entanto, para fins de demonstração da disciplina de gerenciamento de projetos, realizou-se uma estimativa de 'Custo Simulado' com base no esforço humano (horas técnicas) que a equipe empregou, adotando-se um valor referencial simbólico de R\$ 50,00/hora.

Tabela 5 – Orçamento Simulado do Projeto (Para fins acadêmicos)

ITEM	DESCRIÇÃO TÉCNICA	CUSTO REAL	CUSTO SIMULADO (Esforço)
Softwares de Desenv.	Python, VS Code, Git (Open Source)	R\$ 0,00	R\$ 0,00
Banco de Dados	SQLite (Banco relacional local embutido)	R\$ 0,00	R\$ 0,00
Hospedagem / Nuvem	Github Repositories (Academic/Free Tier)	R\$ 0,00	R\$ 0,00
APIs de Mapas	OpenStreetMap (Uso acadêmico gratuito)	R\$ 0,00	R\$ 0,00
Desenvolvimento	Esforço da equipe (Aprox. 120 horas acadêmicas)	R\$ 0,00	R\$ 6.000,00
Gerenciamento	Esforço de planejamento (Aprox. 30 horas)	R\$ 0,00	R\$ 1.500,00
VALOR TOTAL	Custo real despendido vs. Valor do esforço fictício	R\$ 0,00	R\$ 7.500,00

4.6 Plano de Riscos

O Plano de Riscos visa identificar eventos incertos capazes de impactar o cronograma de entregas ou a qualidade final do trabalho acadêmico. As estratégias de mitigação focam no controle do tempo e uso seguro dos computadores pessoais.

Tabela 6 – Matriz de Riscos do Projeto Acadêmico

RISCO	PROBABILIDADE	IMPACTO	PLANO DE MITIGAÇÃO
Atraso no cronograma letivo	Alta	Alto	Divisão clara de tarefas e acompanhamento semanal via grupos do WhatsApp.
Incompatibilidade do dataset	Média	Alto	Escolha prévia de datasets consolidados no Kaggle para a engenharia de dados.
Perda dos arquivos locais (código)	Baixa	Muito Alto	Armazenamento em nuvem institucional (Google Drive) e commits diários no GitHub.
Falta de capacidade computacional	Baixa	Médio	Uso de amostras menores do dataset e uso do Google Colab (Free Tier) se necessário.

4.7 Plano de Comunicação

A governança da equipe foi sustentada por reuniões síncronas semanais via Google Meet e ferramentas gratuitas de colaboração de arquivos.

Tabela 7 – Matriz de Comunicação da Equipe

CANAL	FREQUÊNCIA	CONTEÚDO
Google Meet	Quinzenal	Alinhamento das atividades acadêmicas para a entrega do projeto.
WhatsApp	Diário	Avisos rápidos, comunicação da equipe e dúvidas sobre as tarefas.
GitHub	Contínuo	Versionamento do código Python e scripts estruturados.
Google Drive	Contínuo	Edição colaborativa da documentação do TCC/Projeto Integrador.

5. ANÁLISE DE DADOS

Esta seção detalha o ecossistema prático de Engenharia e Análise de Dados. Todo o pipeline foi construído utilizando Python, alavancando bibliotecas gratuitas (Pandas, NumPy, Matplotlib, Seaborn) e o banco de dados embutido e de código aberto SQLite3, dispensando licenças comerciais.

5.1 Base de Dados

A base de dados utilizada provém de um conjunto de dados públicos educacionais extraído de repositórios abertos (Kaggle), contendo registros simulados de logística urbana de e-commerce ('amazon_delivery.csv'). Esse dataset foi importado para um banco SQLite ('meu_banco.db'), criando um ambiente relacional simulado.

Tabela 8 – Dicionário de Dados das Variáveis Selecionadas

VARIÁVEL	TIPO	DESCRIÇÃO
TpEntrega	Numérico (minutos)	Tempo da entrega – principal KPI do projeto.
Transito	Categórico (Texto)	Densidade do tráfego (Low, Medium, High, Jam).
Clima	Categórico (Texto)	Condição meteorológica registrada.
Veiculo	Categórico (Texto)	Modal de transporte (moto, van).
Area	Categórico (Texto)	Classificação do perímetro (Urbana ou Rural).

5.2 Processo ETL (Extract, Transform, Load)

- **Extract (Extração):** Consumo do arquivo CSV público utilizando a biblioteca Pandas em memória local.
- **Transform (Transformação):** Tratamento de strings, limpeza de valores nulos e cálculo de tempos de entrega via scripts Python.
- **Load (Carga):** Persistência dos dados estruturados no banco local SQLite, viabilizando consultas SQL pela equipe.

5.3 KPIs Desenvolvidos

Utilizando os dados simulados, a equipe codificou os seguintes indicadores:

- KPI 1 – Taxa de Entregas no Prazo (On-Time Delivery): Taxa On-Time (%) = $(\text{Entregas} \leq 120 \text{ min} / \text{Total}) \times 100$
- KPI 2 – Tempo Médio de Entrega: Somatória dos tempos dividida pelo número de entregas.
- KPI 3 – Outliers (Método IQR): Identificação computacional de entregas anômalas.
- KPI 4 e 5 – Impacto do trânsito e da Área Geográfica nos tempos registrados.




Figura 1 – Painel Integrado de Visualização de Dados (DataViz)

5.4 Visualização de Dados (DataViz)

Os resultados foram plotados gratuitamente utilizando a biblioteca Matplotlib e Seaborn do Python.




Figura 2 – Painel Integrado de Visualização de Dados (DataViz)

6. SEGURANÇA DA INFORMAÇÃO

No escopo deste projeto acadêmico, o planejamento da Segurança da Informação foi elaborado de forma teórica e aplicada ao protótipo, evidenciando o domínio da equipe sobre os pilares que protegeriam a aplicação caso ela fosse migrada para um ambiente empresarial.

6.1 Mapeamento de Ameaças

A avaliação mapeou os vetores de riscos teóricos para sistemas logísticos web.

Tabela 9 – Mapeamento e Contramedidas de Segurança do Software

AMEAÇA	PREVENÇÃO (Recomendação / Protótipo)
Injeção de SQL (SQLi)	Uso de queries parametrizadas nas rotinas do SQLite desenvolvidas no Python.
Ransomware (Perda de Código)	Rotina de backup do projeto em serviços gratuitos de nuvem (Google Drive/GitHub).
Cross-Site Scripting (XSS)	Sanitização de strings nas entradas de dados das funções em Python.
Vazamento de Dados	Simulação de criptografia de dados sensíveis na construção teórica do banco de dados.

6.2 Adequação à LGPD (Lei Geral de Proteção de Dados)

O projeto reconhece a necessidade teórica de conformidade com a LGPD (Lei 13.709/2018). No desenvolvimento do protótipo acadêmico, aplicou-se o princípio da minimização de dados: o dataset utilizado foi previamente anonimizado e restrito apenas a variáveis não sensíveis (sem nomes reais, telefones ou CPFs vinculados a pessoas reais).

6.3 Matriz GUT

A equipe aplicou a ferramenta de apoio à decisão (Gravidade, Urgência e Tendência) para elencar os riscos logísticos que exigem maior atenção estrutural no planejamento da empresa fictícia LogiPrime.

Tabela 10 – Matriz GUT de Riscos Operacionais

PROBLEMA / AMEAÇA	G	U	T	PONTUAÇÃO (G×U×T)
Roubo de carga (Ameaça teórica)	5	5	4	100 (Alta)
Bugs no código Python desenvolvido	4	4	4	64 (Média-Alta)
Base de dados acadêmica incompleta	3	3	3	27 (Média)

6.4 Políticas de Autenticação

Para o escopo do projeto, foram recomendadas e implementadas conceitualmente políticas básicas de autenticação no código:

- Armazenamento de Senhas: Uso da biblioteca gratuita (bcrypt) do Python para gerar hashes criptográficos das senhas criadas no banco SQLite local.
- Controle de Acesso: Construção lógica (IF/ELSE) no código para diferenciar acessos simulados de 'Administrador' e 'Operador'.

Tabela 11 – Mecanismos de Autenticação do Protótipo

POLÍTICA	MECANISMO (FERRAMENTA OPEN SOURCE)
Armazenamento	Python bcrypt (Hashing de senhas)
Sessões	JSON Web Token (Simulação em ambiente local)
Acesso	Controle base (RBAC) simulado na lógica da aplicação

7. Pesquisa Operacional

7.1 Introdução à Pesquisa Operacional

A Pesquisa Operacional é uma área da computação e da matemática aplicada utilizada para apoiar a tomada de decisões nas empresas por meio de modelos matemáticos e algoritmos de otimização. No contexto da LogiPrime, sua aplicação foi fundamental para resolver problemas relacionados à distribuição logística, uso da frota e redução de custos operacionais.

A utilização da Pesquisa Operacional permite que a empresa encontre automaticamente a melhor solução possível para determinados cenários, considerando restrições reais da operação, como limite de horas de trabalho, capacidade da frota, demanda de entregas e custos de transporte.

Na LogiPrime, a otimização logística trouxe benefícios importantes, como:

- melhor aproveitamento dos veículos disponíveis;
- redução de desperdícios operacionais;
- diminuição dos custos com transporte;
- aumento da eficiência das entregas;
- maior controle sobre os recursos logísticos.

Além disso, a empresa deixou de realizar decisões apenas de forma manual ou por ordem de chegada, passando a utilizar algoritmos capazes de calcular matematicamente a alternativa mais eficiente para cada situação operacional.

No problema de maximização de lucro, por exemplo, o sistema analisa automaticamente qual combinação entre Motorcycle e Scooter gera o maior retorno financeiro possível dentro do limite diário de horas disponíveis. Já no problema de minimização de custos, o algoritmo determina quais rotas devem ser utilizadas para transportar os pacotes com o menor custo operacional possível.

7.2 Modelagem Matemática

A modelagem matemática consiste em representar problemas reais por meio de equações, variáveis e restrições matemáticas. Dessa forma, o computador consegue processar os dados e encontrar soluções otimizadas para a operação logística.

Variáveis de Decisão

As variáveis representam os valores que o algoritmo precisa descobrir para otimizar o problema.

No modelo de maximização de lucro da LogiPrime:

- x_1 = quantidade de entregas realizadas por Motorcycle;
- x_2 = quantidade de entregas realizadas por Scooter.

Já no modelo de distribuição logística:

- x_{ij} = quantidade de pacotes enviados do galpão iii para o destino jjj .

Função Objetivo

A função objetivo representa aquilo que a empresa deseja otimizar. Dependendo do problema, o objetivo pode ser:

- maximizar lucro;
- minimizar custos;
- minimizar distância;
- maximizar eficiência operacional.

Maximização de Lucro

No primeiro problema desenvolvido, a LogiPrime buscava maximizar o lucro diário da operação logística.

A função objetivo utilizada foi:

$$\max Z = 25x_1 + 15x_2$$

Onde:

- $25x_1$ representa o lucro das entregas realizadas por Motorcycle;
- $15x_2$ representa o lucro das entregas realizadas por Scooter.

O algoritmo busca encontrar os valores ideais de x_1 e x_2 para gerar o maior lucro possível.

Minimização de Custos

No segundo problema, o objetivo era reduzir os custos operacionais das rotas entre galpões e destinos.

A função objetivo foi representada por:

$$\min Z = \sum_{i=1}^n \sum_{j=1}^n m_{cij} x_{ij}$$

Onde:

- c_{ij} representa o custo da rota;
- x_{ij} representa a quantidade transportada naquela rota.

O modelo busca identificar automaticamente a combinação de rotas mais econômica para atender toda a demanda de entregas.

Restrições

As restrições representam os limites operacionais que devem ser respeitados pelo algoritmo.

No problema da LogiPrime, foram utilizadas restrições relacionadas à capacidade operacional e segurança.

Restrição de Horas Disponíveis

A operação possui limite máximo de 150 horas diárias de trabalho.

$$0.5x_1 + 0.75x_2 \leq 150$$

Essa equação garante que o total de horas utilizadas pelas entregas não ultrapasse a capacidade diária dos agentes.

Restrição de Segurança

O número máximo de entregas realizadas por Motorcycle foi limitado a 200 entregas diárias por questões de segurança operacional.

$$x_1 \leq 200$$

Restrição de Atendimento da Demanda

No modelo de distribuição, toda a demanda dos destinos deve ser atendida.

$$\sum_{i=1}^n x_{ij} = D_j$$

Onde:

- D_j representa a demanda total do destino j .

Interpretação dos Resultados

Após a execução dos modelos no Python, o algoritmo encontra automaticamente a melhor solução possível respeitando todas as restrições impostas.

No modelo de maximização, o sistema identifica quantas entregas devem ser realizadas por Motorcycle e Scooter para gerar maior lucro.

No modelo de minimização, o algoritmo define quais rotas devem ser utilizadas para reduzir os custos totais de distribuição.

Dessa forma, a LogiPrime passa a utilizar decisões orientadas por dados e cálculos matemáticos, aumentando significativamente a eficiência da operação logística.

7.3 Scripts Python

Os modelos matemáticos da LogiPrime foram implementados na linguagem Python utilizando bibliotecas especializadas em otimização e manipulação de dados.

Bibliotecas Utilizadas

Python PuLP

A principal biblioteca utilizada foi a PuLP, responsável pela criação e resolução dos modelos de programação linear.

Com ela foi possível:

- definir variáveis de decisão;

- criar funções objetivo;
- adicionar restrições;
- executar algoritmos de otimização.

Foram utilizados recursos como:

- LpProblem
- LpVariable
- LpMaximize
- LpMinimize
- lpSum

SQLite

O SQLite foi utilizado para armazenar e consultar os dados operacionais da LogiPrime.

A conexão com o banco foi realizada através da biblioteca [sqlite3](#), permitindo acessar informações da tabela de entregadores e demais dados logísticos utilizados no modelo.

Pandas

A biblioteca Pandas foi utilizada para manipulação e leitura dos dados extraídos do banco de dados.

Com o Pandas foi possível:

- consultar tabelas;
- organizar os dados;
- preparar informações para os modelos matemáticos.

Lógica do Algoritmo

O algoritmo desenvolvido segue uma sequência lógica baseada em otimização matemática.

Primeiramente, o sistema realiza a leitura dos dados operacionais armazenados no banco de dados da empresa. Em seguida, o modelo matemático é criado definindo:

- variáveis de decisão;
- função objetivo;
- restrições operacionais.

Após essa etapa, o solver matemático executa os cálculos necessários para encontrar a solução ótima do problema.

No caso da maximização de lucro, o algoritmo busca a combinação de entregas que gera o maior retorno financeiro possível.

Já no problema de minimização de custos, o sistema calcula automaticamente a melhor distribuição entre galpões e destinos para reduzir os gastos operacionais.

Otimização das Rotas

A otimização das rotas permitiu melhorar significativamente a eficiência logística da LogiPrime.

O sistema passou a:

- reduzir custos de transporte;
- diminuir desperdícios operacionais;
- melhorar a distribuição da carga;
- utilizar melhor os veículos disponíveis;
- aumentar a capacidade de tomada de decisão da gestão.

Além disso, os scripts desenvolvidos permitem alterar rapidamente variáveis da operação para simular novos cenários logísticos em tempo real.

- Códigos python para Maximização de Lucro e Minimização de Custo:

Código Python:

```

1 from pulp import LpMaximize, LpProblem, LpVariable
2 import sqlite3
3 import pandas as pd
4
5 conn = sqlite3.connect('meu_banco.db')
6
7 entregadores = pd.read_sql("SELECT Veiculo FROM 'logiPrime.Entregadores'", conn)
8
9 model = LpProblem(name="Max_Lucro_LogiPrime", sense=LpMaximize)
10
11 x1 = LpVariable(name="Qtd_Motorcycle", lowBound=0, cat="Integer")
12 x2 = LpVariable(name="Qtd_Scooter", lowBound=0, cat="Integer")
13
14 model += 25 * x1 + 15 * x2, "Lucro_Total"
15 model += (0.5 * x1 + 0.75 * x2 <= 150, "Restricao_Horas_Agentes")
16 model += (x1 <= 200, "Limite_Seguranca_Moto")
17
18 model.solve()
19
20 print(f"Status: {model.status}")
21 print(f"Entregas via Motorcycle: {x1.varValue}")
22 print(f"Entregas via Scooter: {x2.varValue}")
23 print(f"Lucro Máximo: R$ {model.objective.value():.2f}")

```

Status: 1
 Entregas via Motorcycle: 200.0
 Entregas via Scooter: 66.0
 Lucro Máximo: R\$ 5,990.00

Figura 3 - Código python para MInimização de Custo

```

1 from pulp import LpMinimize, LpProblem, LpVariable, lpSum
2
3 galpoes = ['Sao_Paulo', 'Campinas']
4 destinos = ['Santos', 'SJ_Campos', 'Ribeirao_Preto']
5
6 oferta = {'Sao_Paulo': 600, 'Campinas': 450}
7 demanda = {'Santos': 400, 'SJ_Campos': 350, 'Ribeirao_Preto': 300}
8
9 custos = {
10     'Sao_Paulo': {'Santos': 5, 'SJ_Campos': 8, 'Ribeirao_Preto': 15},
11     'Campinas': {'Santos': 12, 'SJ_Campos': 10, 'Ribeirao_Preto': 7}
12 }
13
14 model = LpProblem(name="Min_Custo_LogiPrime", sense=LpMinimize)
15
16 rotas = [(i, j) for i in galpoes for j in destinos]
17 x = LpVariable.dicts("Rota", rotas, lowBound=0, cat="Integer")
18
19 model += lpSum([custos[i][j] * x[(i, j)] for i in galpoes for j in destinos])
20
21 for i in galpoes:
22     model += lpSum([x[(i, j)] for j in destinos]) <= oferta[i]
23
24 for j in destinos:
25     model += lpSum([x[(i, j)] for i in galpoes]) == demanda[j]
26
27 model.solve()
28
29 print(f"Status: {model.status}")
30 for i in galpoes:
31     for j in destinos:
32         if x[(i, j)].varValue > 0:
33             print(f"De {i} para {j}: {x[(i, j)].varValue} pacotes")

```

Status: 1
 De Sao_Paulo para Santos: 400.0 pacotes
 De Sao_Paulo para SJ_Campos: 200.0 pacotes
 De Campinas para SJ_Campos: 150.0 pacotes
 De Campinas para Ribeirao_Preto: 300.0 pacotes

Figura 4 - Código python para MInimização de Custo

7.4 Análise de Cenários

A análise de cenários (What-If Analysis) foi utilizada para simular situações críticas capazes de impactar diretamente a operação logística da LogiPrime. Essa abordagem permite alterar variáveis do sistema e verificar automaticamente os impactos operacionais e financeiros gerados pelas mudanças nas condições da operação.

Por meio da modelagem matemática desenvolvida em Python, a empresa consegue testar rapidamente diferentes situações reais, permitindo maior capacidade de adaptação, redução de riscos e apoio à tomada de decisões estratégicas.

Cenário 1 — Condições Climáticas Severas (Weather = Stormy)

No primeiro cenário analisado, foi simulada uma situação de crise causada pelo agravamento das condições climáticas identificadas na base de dados pela variável Weather = Stormy.

Nesse contexto, a gerência decidiu reduzir drasticamente o número máximo de entregas realizadas por caminhão devido aos riscos operacionais causados pela tempestade. Assim, o limite de segurança operacional foi alterado de 200 para apenas 80 entregas diárias.

A restrição do modelo passou de:

$$x_1 \leq 200$$

para:

$$x_1 \leq 80$$

Após executar novamente o algoritmo, o modelo matemático adapta automaticamente toda a operação logística às novas restrições impostas pela tempestade.

O sistema passou a recomendar exatamente o novo limite máximo permitido de 80 entregas por caminhão, garantindo que a operação continuasse funcionando dentro das condições de segurança definidas pela empresa.

Mesmo com a redução da capacidade operacional e da lucratividade total da operação, o algoritmo continuou encontrando a melhor alocação possível dos recursos disponíveis. Isso demonstra a capacidade da Pesquisa Operacional em gerar soluções rápidas e eficientes mesmo em cenários críticos e instáveis.

```
[4] ▶ 1 from pulp import LpMaximize, LpProblem, LpVariable
    2 import sqlite3
    3 import pandas as pd
    4
    5 conn = sqlite3.connect('meu_banco.db')
    6
    7 entregadores = pd.read_sql("SELECT Veiculo FROM 'logiPrime.Entregadores'", conn)
    8
    9 model = LpProblem(name="Max_Lucro_LogiPrime", sense=LpMaximize)
   10
   11 x1 = LpVariable(name="Qtd_Motorcycle", lowBound=0, cat="Integer")
   12 x2 = LpVariable(name="Qtd_Scooter", lowBound=0, cat="Integer")
   13
   14 model += 25 * x1 + 15 * x2, "Lucro_Total"
   15
   16 model += (0.5 * x1 + 0.75 * x2 <= 150, "Restricao_Horas_Agentes")
   17
   18 model += (x1 <= 80, "Limite_Seguranca_Moto_Stormy")
   19
   20 model.solve()
   21
   22 print(f"Status: {model.status}")
   23 print(f"Entregas via Motorcycle: {x1.varValue}")
   24 print(f"Entregas via Scooter: {x2.varValue}")
   25 print(f"Lucro Máximo: R$ {model.objective.value():.2f}")

... Status: 1
Entregas via Motorcycle: 80.0
Entregas via Scooter: 146.0
Lucro Máximo: R$ 4,190.00
```

Figura 5 - What-if - Condições climáticas Severas

Cenário 2 — Trânsito Severo (Traffic = Jam)

O segundo cenário analisado considerou uma situação de congestionamento intenso identificada na base de dados pela variável Traffic = Jam.

Nesse caso, o trânsito severo provoca aumento significativo no tempo de deslocamento dos caminhões, elevando diretamente os custos operacionais da empresa devido ao maior consumo de combustível e aumento do tempo de utilização da frota.

Com isso, o custo operacional médio das entregas realizadas por caminhão, inicialmente estimado em R\$18,00 por operação, poderia aumentar para valores ainda maiores dependendo das condições do tráfego.

Ao alterar os custos operacionais no código do modelo matemático, o sistema calcula automaticamente o impacto financeiro causado pelo congestionamento.

A função de minimização de custos utilizada no modelo permaneceu baseada em:

$$\min Z = \sum_{i=1}^n \sum_{j=1}^n m_{cij} x_{ij}$$

Porém, com os novos valores de custo inseridos nas rotas afetadas pelo trânsito, o algoritmo passou a redistribuir automaticamente as entregas buscando minimizar os impactos financeiros da operação.

Dessa forma, o sistema permite que a LogiPrime avalie rapidamente como alterações no trânsito influenciam os custos totais da distribuição logística, auxiliando a empresa na criação de estratégias para reduzir prejuízos, melhorar o planejamento operacional e manter a eficiência das entregas mesmo em situações críticas de mobilidade urbana.

```
22 },
23 "Campinas": {
24   "Santos": 18,
25   "SJ_Campos": 16,
26   "Ribeirao_Preto": 12
27 }
28 }
29
30 model = lpProblem(
31   name="Min_Custo_LogiPrime",
32   sense=lpMinimize
33 )
34
35 rotas = [(i, j) for i in galpoes for j in destinos]
36
37 x = lpVariable.dicts(
38   "xota",
39   rotas,
40   lb=0, ub=9,
41   cat="Integer"
42 )
43
44 model += lpSum(
45   [custos[i][j] * x[(i, j)]
46    for i in galpoes
47     for j in destinos]
48 )
49
50 for i in galpoes:
51   model += lpSum(
52     [x[(i, j)] for j in destinos]
53   ) <= oferta[i]
54
55 for j in destinos:
56   model += lpSum(
57     [x[(i, j)] for i in galpoes]
58   ) == demanda[j]
59
60 model.solve()
61
62 print("Status: ", model.status)
63
64 for i in galpoes:
65   for j in destinos:
66     if x[(i, j)].varValue > 0:
67       print("De (i) para (j): ", x[(i, j)].varValue, "pacotes")
68
69
70 status: 1
71 De Sao_Paulo para Santos: 400.0 pacotes
72 De Sao_Paulo para SJ_Campos: 50.0 pacotes
73 De Campinas para SJ_Campos: 200.0 pacotes
74 De Campinas para Ribeirao_Preto: 120.0 pacotes
```

Figura 6 - What-if - Trânsito Severo

Análise Crítica da Otimização

Os resultados obtidos demonstraram que a aplicação da Pesquisa Operacional trouxe melhorias significativas para a gestão logística da LogiPrime.

A utilização da modelagem matemática e dos algoritmos desenvolvidos em Python permitiu transformar problemas operacionais complexos em modelos computacionais capazes de gerar soluções otimizadas automaticamente.

Além disso, a análise de cenários mostrou que o sistema possui elevada capacidade de adaptação dinâmica. Ao modificar variáveis operacionais relacionadas às condições climáticas e ao trânsito, o algoritmo calcula instantaneamente novas soluções logísticas respeitando todas as restrições impostas.

Com isso, a LogiPrime deixa de atuar apenas de maneira reativa diante de crises operacionais e passa a utilizar inteligência analítica para apoiar decisões estratégicas, reduzir perdas financeiras, aumentar a previsibilidade logística e melhorar a eficiência das operações de transporte.

8. Resultados Obtidos

A implementação da modelagem matemática e das técnicas de Pesquisa Operacional no sistema logístico da LogiPrime trouxe resultados significativos para a eficiência operacional da empresa. A utilização dos algoritmos desenvolvidos em Python permitiu transformar processos que anteriormente eram realizados de forma manual em decisões automatizadas baseadas em otimização matemática e análise de dados.

Antes da aplicação do projeto, a empresa realizava suas operações logísticas utilizando critérios simples de distribuição, muitas vezes apenas por ordem de chegada. Esse modelo operacional gerava desperdício de recursos, baixa previsibilidade e aumento dos custos relacionados ao transporte e à utilização da frota.

Com a aplicação dos modelos de maximização de lucro e minimização de custos, a LogiPrime passou a operar de forma mais estratégica, utilizando dados e cálculos matemáticos para apoiar a tomada de decisões.

Redução de Custos Operacionais

Um dos principais resultados obtidos foi a redução dos custos logísticos da operação.

O modelo de minimização de custos permitiu identificar automaticamente as rotas mais econômicas entre galpões e destinos, reduzindo desperdícios relacionados ao transporte e melhorando a distribuição da carga entre os centros logísticos.

A otimização das rotas contribuiu diretamente para:

- redução do consumo de combustível;
- diminuição de deslocamentos desnecessários;
- melhor aproveitamento da capacidade dos caminhões;
- redução de gastos operacionais da frota.

Com base nas simulações realizadas, estima-se uma redução operacional aproximada de 20% nos custos logísticos em comparação ao processo anterior realizado sem otimização matemática.

Redução do Tempo de Planejamento

Outro resultado importante foi a redução significativa do tempo necessário para o planejamento das operações logísticas.

Anteriormente, a definição das rotas e da distribuição das entregas exigia análises manuais e demoradas. Após a implementação dos scripts em Python, os cálculos passaram a ser executados automaticamente em poucos segundos.

Isso permitiu:

- maior agilidade operacional;
- respostas rápidas diante de mudanças no cenário logístico;
- adaptação imediata em situações críticas;
- aumento da produtividade da equipe responsável pela gestão das entregas.

Além disso, a análise de cenários (What-If) possibilitou calcular instantaneamente novas soluções operacionais em casos de tempestades severas e congestionamentos intensos.

Melhoria da Eficiência da Frota

A modelagem matemática também proporcionou melhor utilização dos veículos disponíveis na operação.

No modelo de maximização de lucro, o algoritmo passou a calcular automaticamente quantas entregas deveriam ser realizadas por Motorcycle e Scooter considerando:

- capacidade operacional;
- limite de horas disponíveis;
- restrições de segurança;
- retorno financeiro de cada modal.

Com isso, a empresa passou a utilizar a frota de maneira mais inteligente, evitando sobrecarga operacional e desperdício de capacidade logística.

A otimização proporcionou:

- melhor distribuição das entregas;
- aumento da produtividade da frota;
- maior equilíbrio operacional;
- utilização mais eficiente dos recursos disponíveis.

Aumento da Segurança Operacional

Outro resultado relevante foi o fortalecimento da segurança operacional da empresa.

Os modelos desenvolvidos passaram a considerar restrições relacionadas às condições climáticas e aos limites de segurança da operação.

Durante a análise de cenários, foi possível reduzir automaticamente o limite de entregas realizadas por caminhão em situações de tempestade (Weather = Stormy), diminuindo os riscos operacionais enfrentados pelos motoristas.

A alteração da restrição:

$x_1 \leq 80$

permitiu que o sistema adaptasse imediatamente toda a operação às novas condições climáticas, garantindo continuidade operacional com maior segurança.

Além disso, o sistema também passou a considerar cenários de trânsito severo (Traffic = Jam), auxiliando na prevenção de atrasos excessivos, aumento de custos e desgaste operacional da frota.

9. Conclusão

O desenvolvimento do projeto LogiPrime demonstrou como a aplicação da tecnologia e da Pesquisa Operacional pode transformar a gestão logística de uma empresa, tornando os processos mais inteligentes, eficientes e seguros.

Os objetivos propostos foram alcançados com sucesso, especialmente no que se refere à otimização das entregas, redução de custos operacionais, melhoria da utilização da frota e apoio à tomada de decisões estratégicas. A implementação dos modelos matemáticos em Python permitiu automatizar análises complexas e encontrar soluções otimizadas para diferentes cenários logísticos.

Outro ponto importante foi a integração entre diferentes áreas do conhecimento ao longo do projeto. Foram aplicados conceitos relacionados à:

- Pesquisa Operacional;
- Banco de Dados;
- Programação em Python;
- Modelagem Matemática;
- Logística e Gestão Operacional.

Essa integração demonstrou a importância da interdisciplinaridade no desenvolvimento de soluções tecnológicas voltadas para problemas reais do mercado.

Além disso, o projeto evidenciou como a tecnologia possui papel fundamental na logística moderna. A utilização de algoritmos de otimização e análise de dados permite que empresas tomem decisões mais rápidas, reduzam desperdícios, aumentem a produtividade e melhorem sua capacidade de adaptação diante de situações críticas.

As análises de cenários (What-If) mostraram que o sistema desenvolvido consegue responder rapidamente a mudanças operacionais, como tempestades severas e congestionamentos intensos, recalculando automaticamente novas soluções para minimizar impactos financeiros e operacionais.

Como possibilidades de melhorias futuras, o projeto pode evoluir para incluir:

- integração com dados em tempo real;
- utilização de inteligência artificial para previsão de demanda;
- monitoramento via GPS da frota;
- cálculo automático de rotas utilizando mapas digitais;
- dashboards interativos para visualização operacional;
- integração com sensores IoT para monitoramento logístico.

Dessa forma, conclui-se que o projeto desenvolvido para a LogiPrime representa uma solução eficiente, moderna e escalável para otimização logística, demonstrando na prática os benefícios da aplicação da tecnologia e da modelagem matemática no ambiente corporativo.